# GIỚI THIỆU VỀ HỌC MÁY

"Machine Learning: Field of study that gives computers the ability to learn without being explicitly programmed." -Arthur Samuel (1959)

## Traditional Programming


## Machine Learning

## Định nghĩa

**Definition (Machine learning (ML))**

Tom Mitchell - "Máy tính được gọi là học từ kinh nghiệm (dữ liệu) E với tác vụ (dự đoán, phân lớp, gom nhóm) T và được đánh giá bởi độ đo (độ chính xác) P nếu máy tính khiến tác vụ T này cải thiện được độ chính xác P thông qua dữ liệu E cho trước."

# Defining the Learning Task

Improve on task T, with respect to
performance metric P, based on experience E

T: Playing checkers
P: Percentage of games won against an arbitrary opponent
E: Playing practice games against itself

T: Recognizing hand-written words
P: Percentage of words correctly classified
E: Database of human-labeled images of handwritten words

T: Driving on four-lane highways using vision sensors
P: Average distance traveled before a human-judged error
E: A sequence of images and steering commands recorded while observing a human driver.

T: Categorize email messages as spam or legitimate.
P: Percentage of email messages correctly classified.
E: Database of emails, some with human-given labels

# Machine learning vs AI

Ta cần AI để tạo ra các thiết bị thông minh, nhưng để chúng thực sự thông minh và ứng sử như con người, ta cần ML.
Chinh phục AI mặc dù vẫn là mục đích tối thượng của machine learning, nhưng hiện tại machine learning tập trung vào những mục tiêu ngắn hạn hơn như: Làm cho máy tính có những khả năng nhận thức cơ bản của con người như nghe, nhìn, hiểu được ngôn ngữ, giải toán, lập trình, ...
Các ứng dụng như:

- Trợ lý ảo: IBM Watson, Google Now, Cortana, alexa, Siri, Bixby, ...
- Robot: Big Dog robot (chó robot trong quân đội mỹ), asimo (Honda), ...
- Các hệ thống phương tiện thông minh, xe không người lái (Google), xe tự tuần trong quân đội, ...

# Machine learning vs Big Data

Big Data thực chất không phải là một ngành khoa học chính thống, chỉ là cụm từ được xây dựng bởi truyền thông. Big Data là một hệ quả tất yếu của mạng Internet ngày càng có nhiều kết nối. Như Facebook, Twitter, youtube, . . .

# Machine learning vs Big Data

Với kho dữ liệu đồ xộ và chứa một khối tri thức khổng lồ. Và từ những dữ liệu này ta có thể hiểu thêm về con người và xã hội. Cụ thể:

- Từ danh sách tìm kiếm của người dùng $\Rightarrow$ sở thích của người dùng và giới thiệu những thứ phù hợp với nhu cầu và sở thích của người dùng.
- Từ mối quan hệ và tương tác của người dùng trên MXH $\Rightarrow$ gom nhóm cộng đồng theo sở thích, công việc, ...
- Từ các tương tác của người sử dụng, có thể phát hiện ra các hành vi sai phạm, ...

Big Data chỉ thực sự bắt đầu từ khi ta hiểu được gía trị của thông tin ẩn chứa trong dữ liệu, và có đủ tài nguyên cũng như công nghệ để có thể khai thác chúng trên quy mô khổng lồ. Machine learning chính là thành phần mấu chốt của công nghệ đó.

# Machine learning vs Phân tích dự báo

ML có mỗi liên hệ mật thiết đối với thống kê. Tuy nhiên ML, không chỉ đơn thuần sử dụng các mô hình thống kê để ghi nhớ lại sự phân bố dữ liệu, nó có khả năng tổng quát hóa những gì đã được nhìn thấy và dự đoán cho những trường hợp chưa được nhìn thấy. Như vậy ta có thể nói ML có thể dự đoán tương lai, nhưng chỉ khi tương lai có mối liên hệ mật thiết với hiện tại.

Một số ứng dụng dự đoán như:

- Dự đoán xu hướng thị trường, bất động sản, chính trị, . . .
- Dự báo thời tiết, khi hậu, thiên tai,. . .
- . . .

# Quá trình Phát Triển (Pre-Deep Learning)

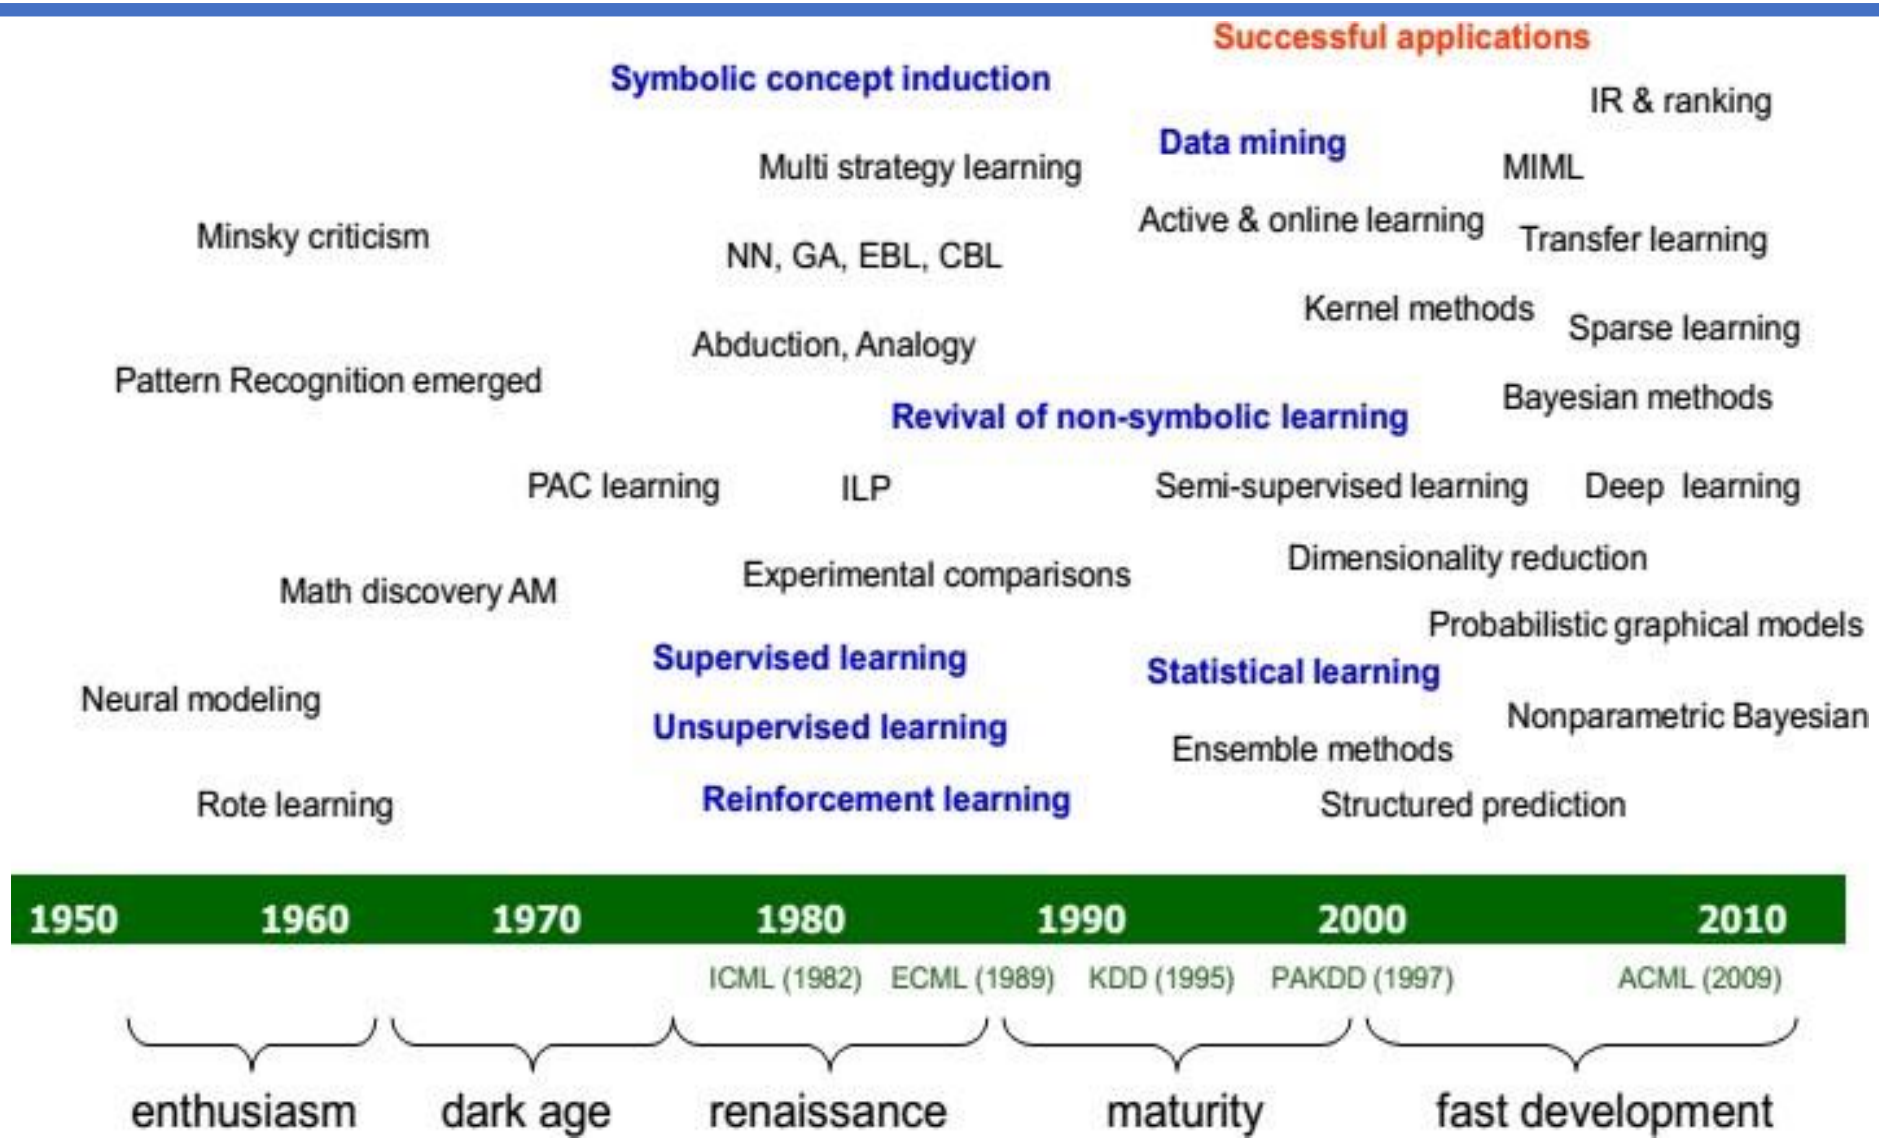

# Các phương pháp học máy

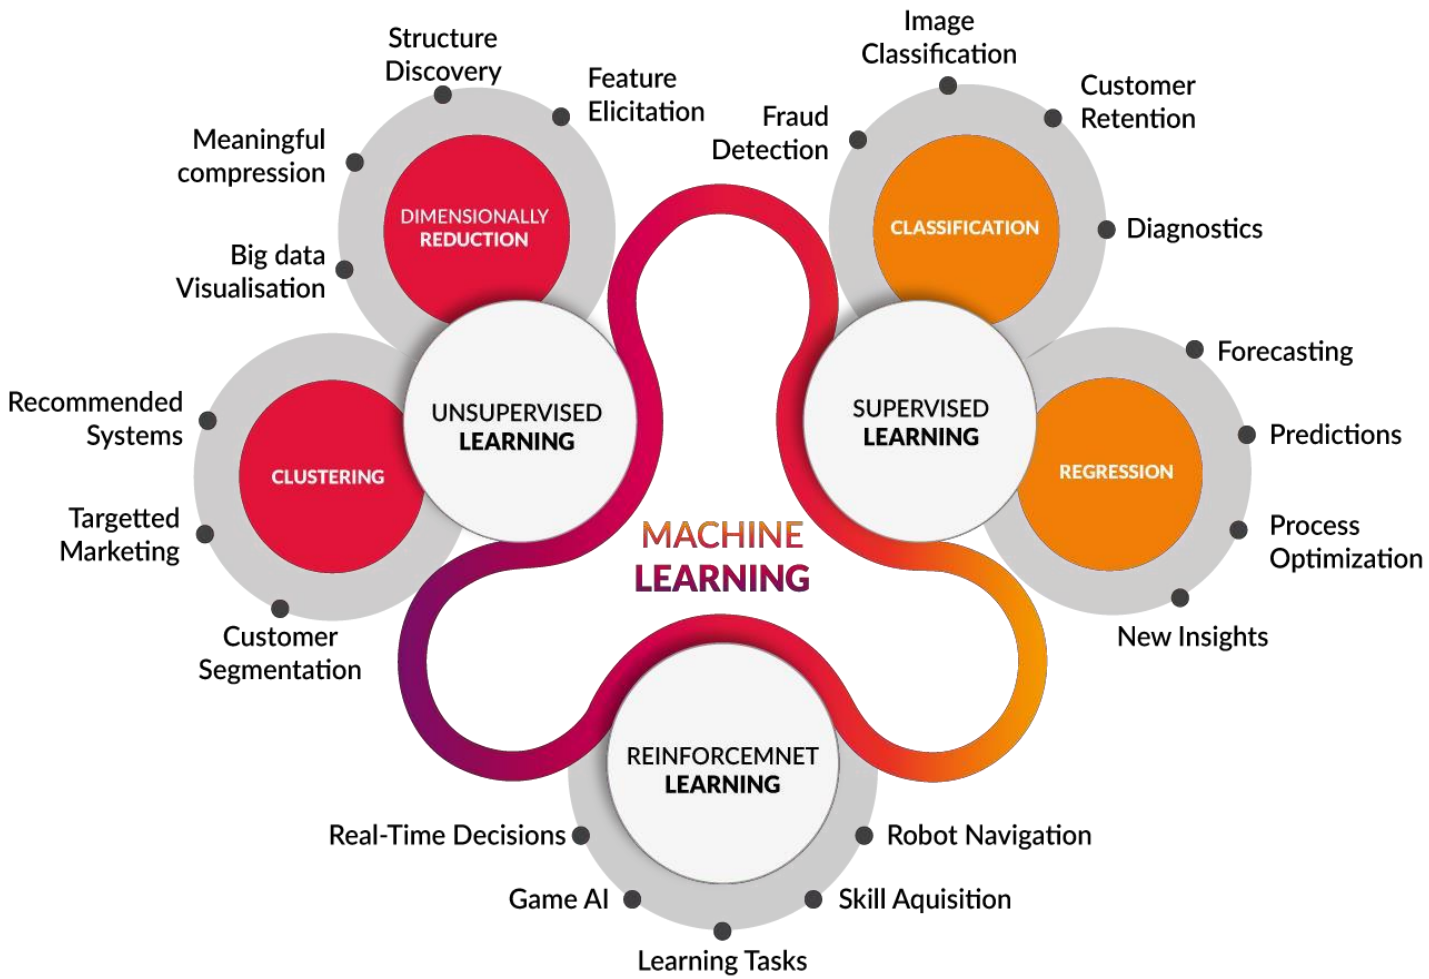

# Supervised learning

## Definition

Supervised learning là khi ta có tập quan sát $\mathcal{X} = \{x_1, x_2, \ldots, x_N\}$ và tập nhãn tương ứng $\mathcal{Y} = \{y_1, y_2, \ldots, y_N\}$, trong đó $x_i, y_i$ là các vector. Các cặp dữ liệu biết trước $(x_i, y_i) \in \mathcal{X} \times \mathcal{Y}$ được gọi là training data. Từ tập training data, ta cần tạo ra một hàm số ánh xạ mỗi phần tử từ tập $\mathcal{X}$ sang một phần tử tương ứng của tập $\mathcal{Y}$:

$$y_i \approx f(x_i), \forall_i = 1, 2, \ldots, N \tag{1}$$

Vì vậy kết quả của dạng toán này phụ thuộc vào tập dữ liệu training set có tính "right answers".

## Supervised learning

Thuật toán supervised learning được chia nhỉ thành hai loại chính:

- Classification(Phân loại) nếu các label của input data được chia thành một số hữu hạn nhóm. Ví dụ: Gmail xác định xem một email có phải là spam hay không; các hãng tín dụng xác định xem một khách hàng có khả năng thanh toán nợ hay không.
- Regression (Hồi quy) Nếu label không được chia thành các nhóm mà là một giá trị thực cụ thể. Ví dụ: một căn nhà rộng $x$ ($m^2$), có $y$ phòng nhủ và cách trung tâm thành phố $z$ km sẽ có giá là bao nhiêu?

# Supervised Learning: Classification

- Given $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$
- Learn a function $f(x)$ to predict $y$ given $x$
  - $y$ is categorical == classification

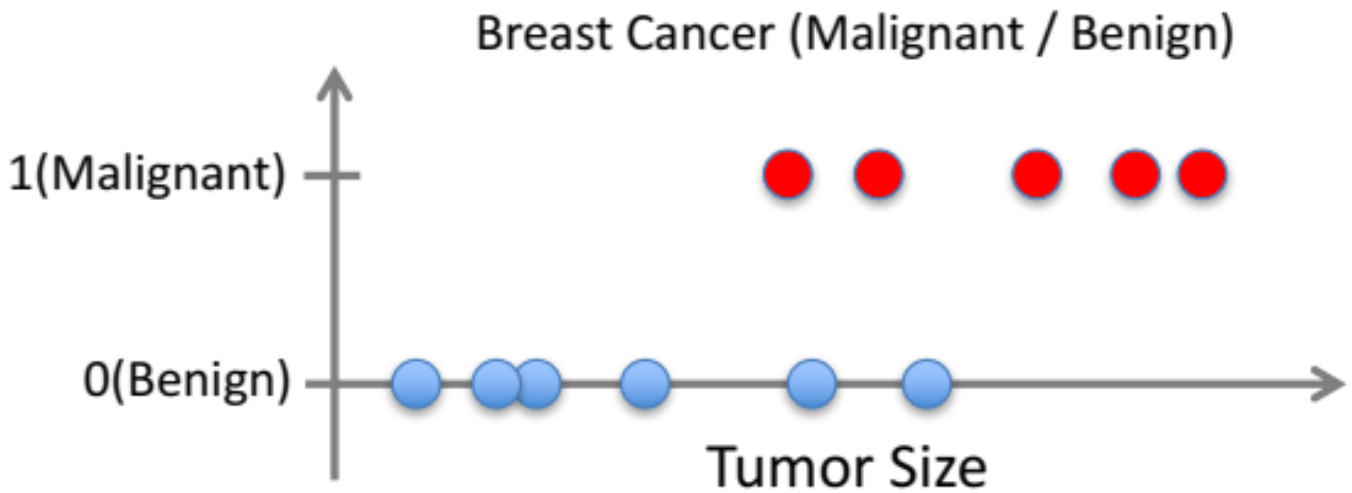

# Supervised Learning: Regression

- Given $(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)$
- Learn a function $f(x)$ to predict $y$ given $x$
  - $y$ is real-valued == regression

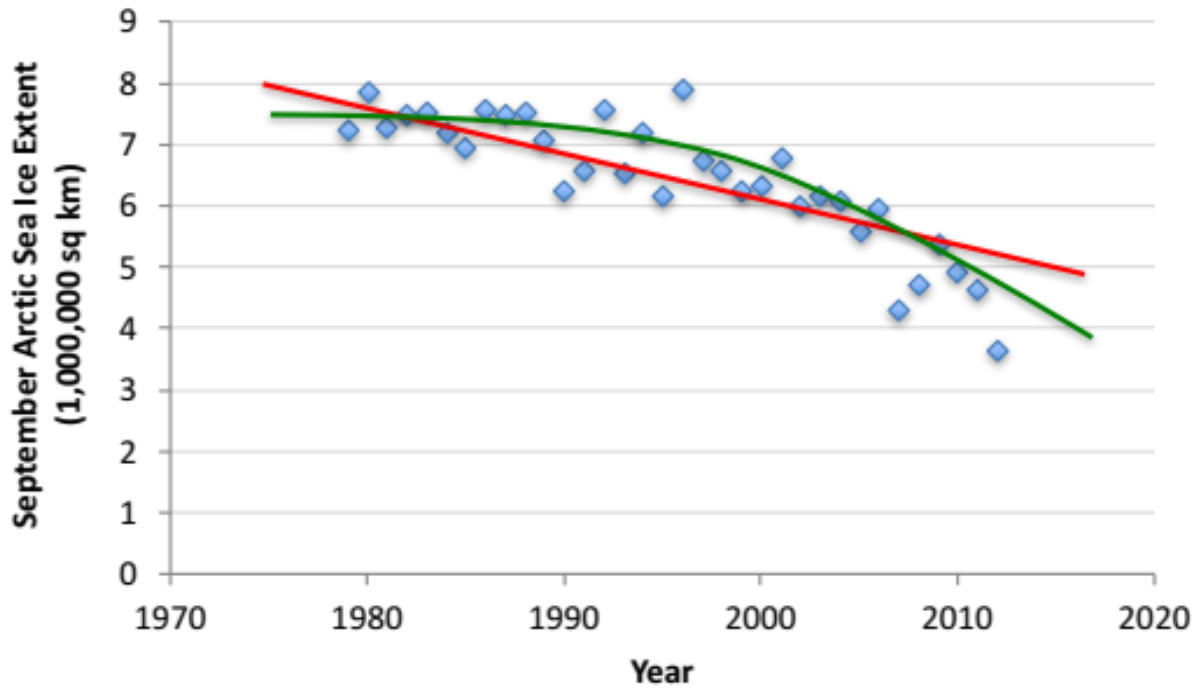

## Định nghĩa

Unsupervised learning là khi chúng ta chỉ có dữ liệu quan sát đầu vào $\mathcal{X}$ mà không biết nhãn $\mathcal{Y}$ tương ứng.Thuật toán unsupervised learning sẽ dựa vào cấu trúc của dữ liệu để thực hiện một công việc nào đó.
Unsupervised learning được chia nhỏ thành hai loại:

- Clustering: Là bài toán phân nhóm toàn bộ dữ liệu $\mathcal{X}$ thành các nhóm nhỏ dựa trên sự liên quan giữa các dữ liệu trong nhóm.
  VD: Phân nhóm khách hàng dựa trên hành vi mua hàng, phát hiện cộng đồng trong mạng xã hội, . . .
- Association: Là bài toán khám phá quy luật dựa trên tập dữ liệu cho trước.

# Unsupervised Learning

- Given $x_1$, $x_2$, ..., $x_n$ (without labels)
- Output hidden structure behind the $x$'s
  - E.g., clustering

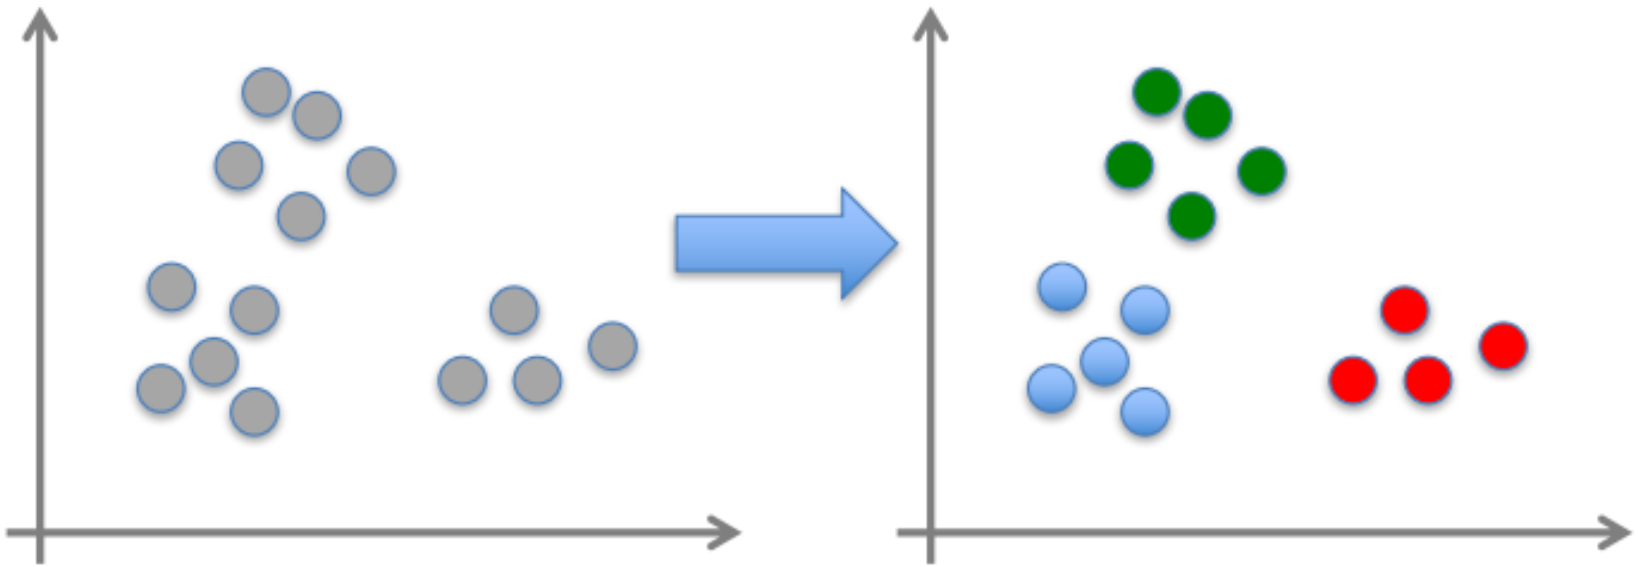

# Unsupervised Learning

- Independent component analysis – separate a combined signal into its original sources

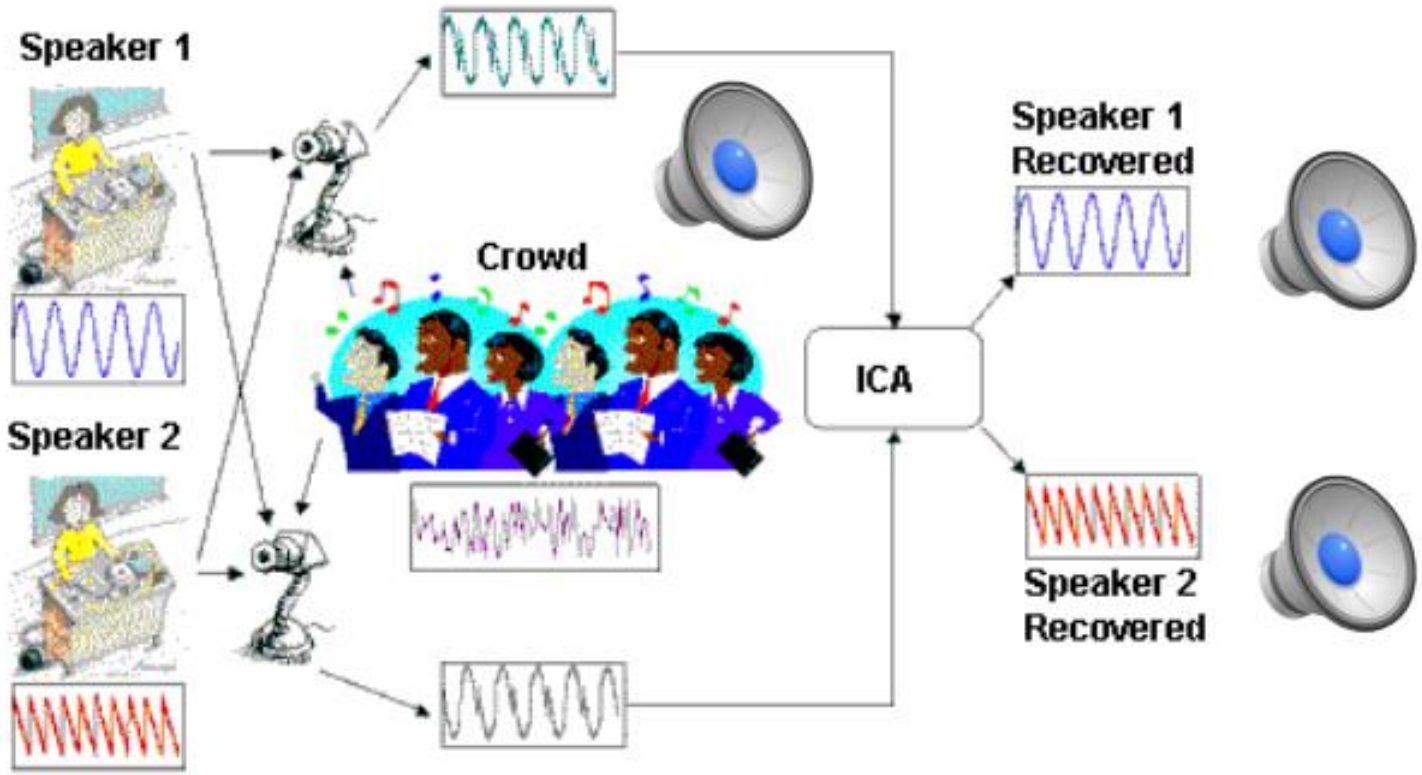

# When Do We Use Machine Learning?

ML is used when:

- Human expertise does not exist (navigating on Mars)
- Humans can't explain their expertise (speech recognition)
- Models must be customized (personalized medicine)
- Models are based on huge amounts of data (genomics)




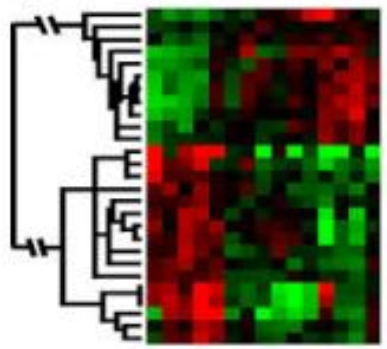

Learning isn't always useful:

- There is no need to "learn" to calculate payroll

# Autonomous Cars

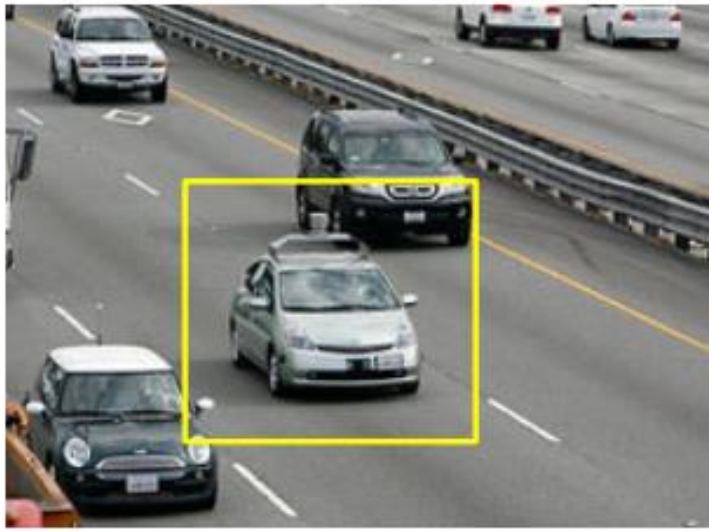

- Nevada made it legal for autonomous cars to drive on roads in June 2011
- As of 2013, four states (Nevada, Florida, California, and Michigan) have legalized autonomous cars

Penn's Autonomous Car →
(Ben Franklin Racing Team)

# Scene Labeling via Deep Learning

# Machine Learning in Automatic Speech Recognition

A Typical Speech Recognition System

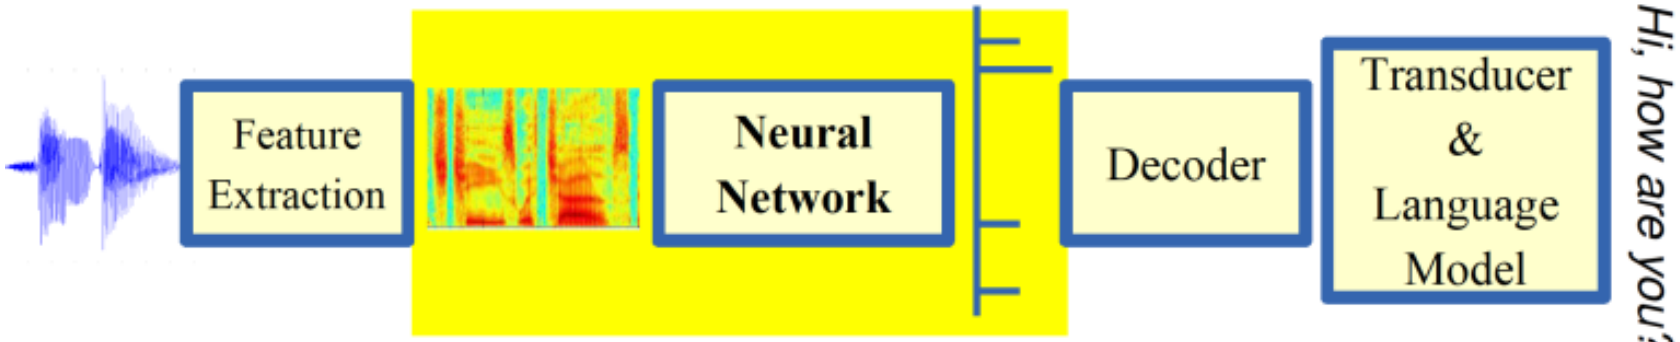


ML used to predict of phone states from the sound spectrogram

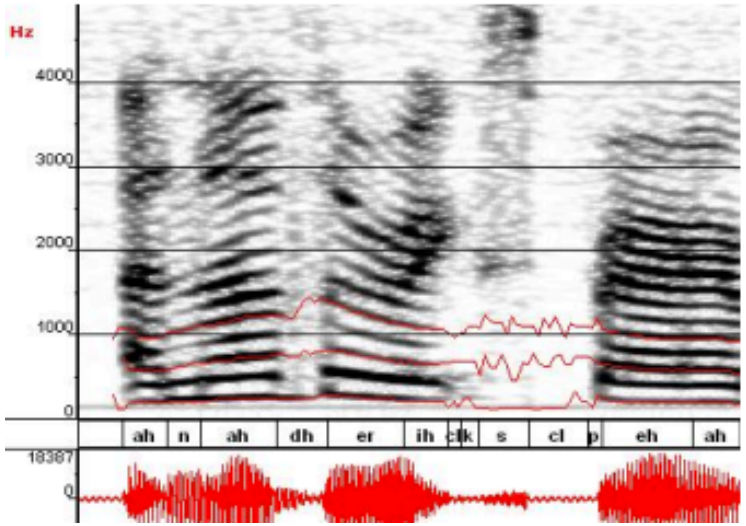


Deep learning has state-of-the-art results

| # Hidden Layers | 1 | 2 | 4 | 8 | 10 | 12 |
|---|---|---|---|---|---|---|
| Word Error Rate % | 16.0 | 12.8 | 11.4 | 10.9 | 11.0 | 11.1 |

Baseline GMM performance = 15.4%

[Zeiler et al. "On rectified linear units for speech recognition" ICASSP 2013]

21

# Impact of Deep Learning in Speech Technology


lide credit: Li Deng, MS Research

# QUY TRÌNH XÂY DỰNG HỆ THỐNG

# Các bước xây dựng mô hình học máy

- Thu thập dữ liệu
- Chuẩn bị dữ liệu
- Lựa chọn mô hình
- Huấn luyện mô hình
- Đánh giá mô hình
- Thay đổi tham số/mô hình
- Áp dụng mô hình

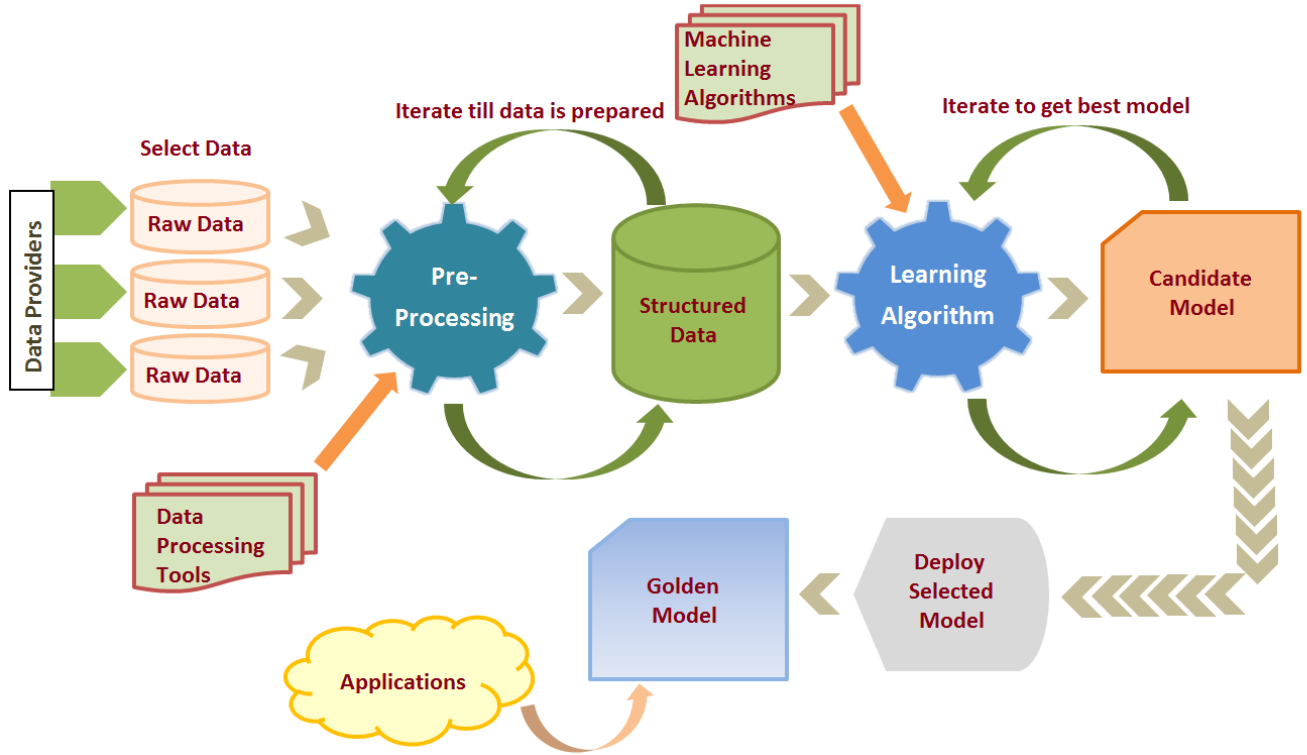

# Thu thập dữ liệu (Data Collection)

- Chất lượng và khối lượng dữ liệu ảnh hưởng trực tiếp đến mô hình học máy
- Dữ liệu thực tế hay dữ liệu phòng lab
- Dữ liệu thực tế: dữ liệu của bạn hay dữ liệu nguồn khác
- Đánh giá dữ liệu: độ lớn, nguồn, độ phức tạp, độ mất mát …
- Lưu trữ dữ liệu: Tập trung hay phân tán

# Chuẩn bị dữ liệu (Data Preparation)

- Lý do chuẩn bị dữ liệu
  - Phù hợp với thuật toán, công cụ
  - Dữ liệu không sạch: không đầy đủ, nhiễu, không nhất quán
- Các vấn đề trong chuẩn bị dữ liệu
  - Khám phá dữ liệu
  - Làm sạch dữ liệu
  - Tích hợp dữ liệu
  - Biến đổi, rời rạc hóa và chuẩn hóa dữ liệu
  - Cân bằng dữ liệu
  - Rút gọn thuộc tính

# Khám phá dữ liệu (Data exploration)

- Thuộc tính ảnh hưởng tới quyết định
- Mối liên hệ giữa các thuộc tính

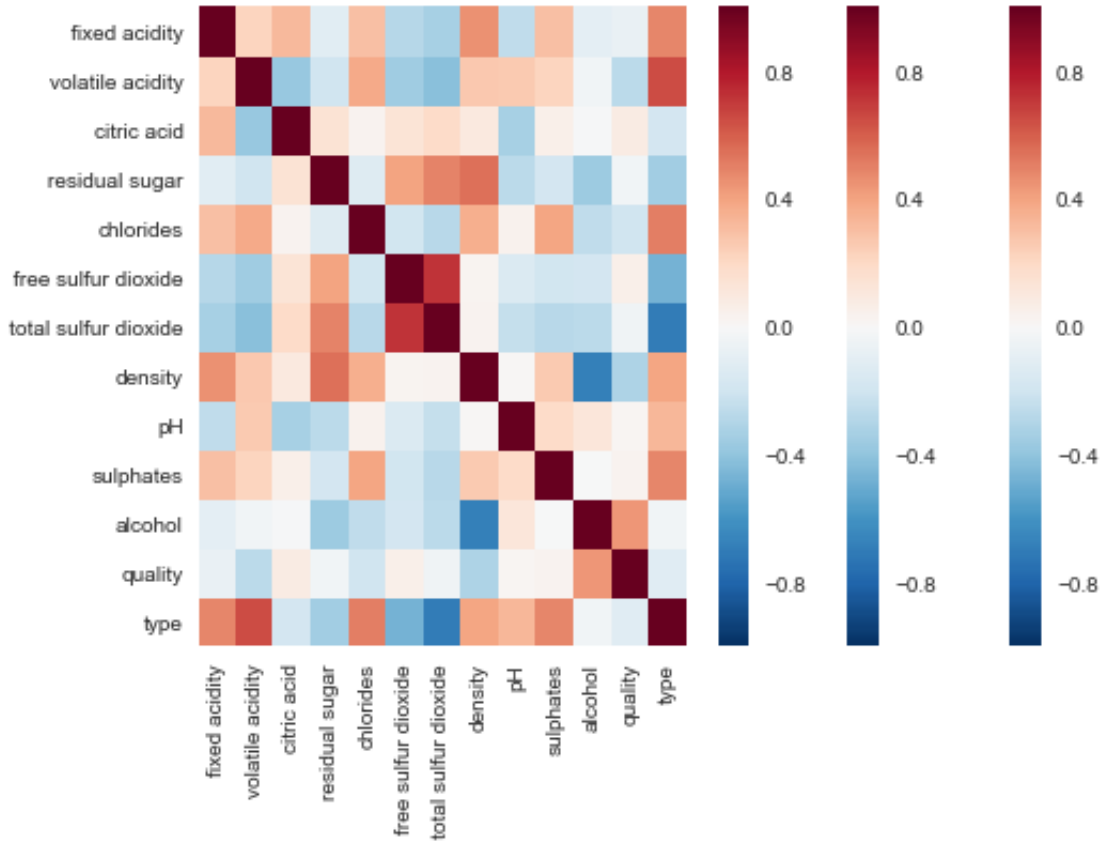

# Làm sạch dữ liệu (Data cleansing)

- Dữ liệu mất mát (missing data)
  - Vì một lý do nào đó mà dữ liệu bị mất mát (dữ liệu không được thu thập, lỗi lưu trữ ...)
  - Một vài giải pháp:
    - Bỏ qua bản ghi hoặc thuộc tính chứa thông tin bị mất mát
    - Điền thông tin mới với: ngẫu nhiên hoặc liên quan đến các dữ liệu xung quanh
- Dữ liệu có nhiễu: giá trị không phù hợp ...
- Dữ liệu trùng lặp
  - Xảy ra khi tổng hợp nhiều nguồn tin khác nhau.

# Biến đổi dữ liệu

- Rời rạc hóa (discretization)
  - Biến đổi dữ liệu từ dạng liên tục (continuous) sang rời rạc (discrete)
  - Nhiều model yêu cầu dữ liệu ở dạng rời rạc: cây phân lớp
  - Cho phép thu gọn dữ liệu

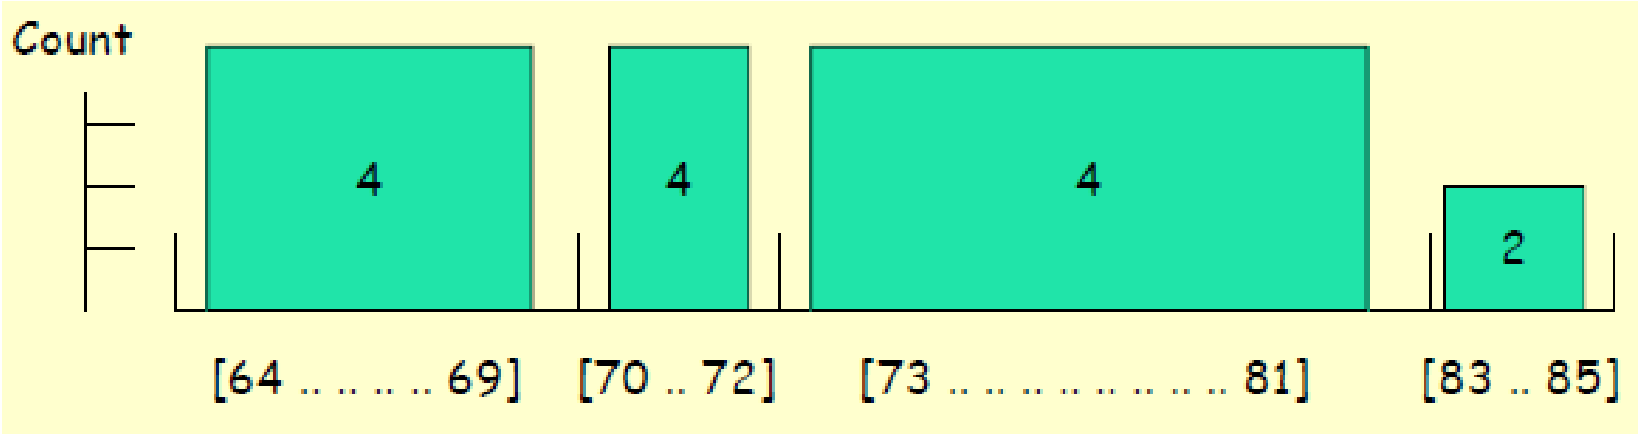

# Biến đổi dữ liệu

- Chuẩn hóa dữ liệu (normalization)
  - Với nhiều mô hình dựa trên độ đo khoảng cách (distance-based method), việc chuẩn hóa giúp cho các thuộc tính có sự ảnh hưởng cân bằng với nhau
    - Ví dụ tuổi từ 0-99, lương từ 1 triệu VNĐ tới 1 tỉ VNĐ
  - Chuẩn hóa các thuộc tính về các khoảng tương tự nhau hoặc miền giá trị từ 0 tới 1
  - Các phương pháp:
    - min-max normalization

$$z = \frac{x \text{ - } \min(x)}{\max(x) \text{ - } \min(x)}$$

    - z-score normalization (standardization)

$$z = \frac{x - \mu}{\sigma}$$

# Cân bằng dữ liệu

- Dữ liệu bất cân bằng khi một lớp đối tượng có lượng bản ghi lớn hơn hẳn các lớp còn lại
- Bài toán phát hiện phishing
  - Trong 1 triệu email mới có khoảng 30 là phishing

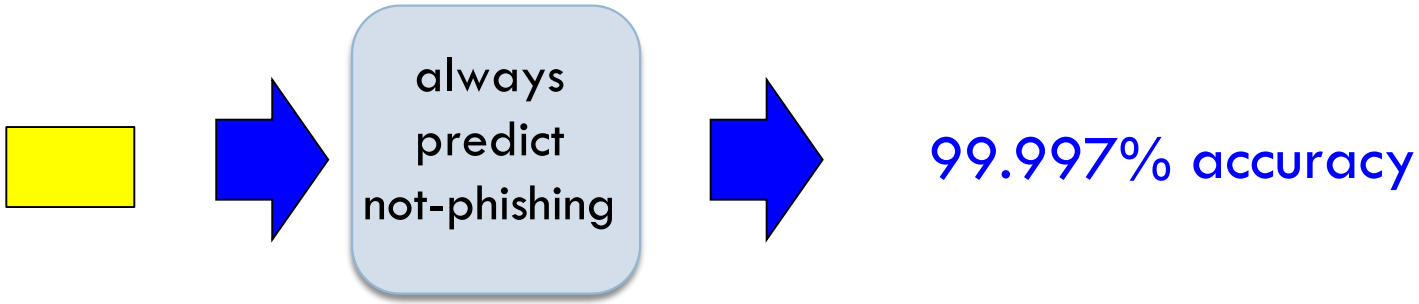


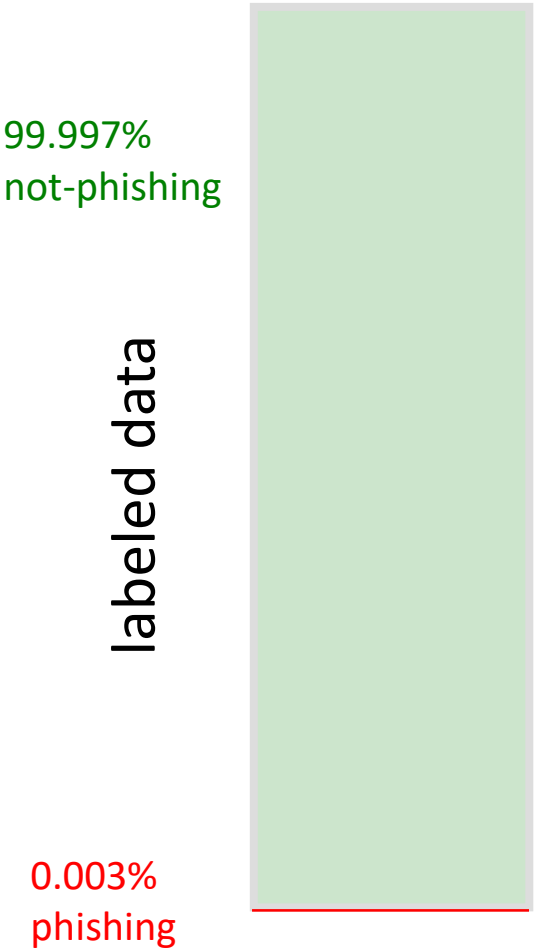

# Rút gọn thuộc tính (Feature Selection)

- Rút gọn thuộc tính là quá trình chọn tập con tối ưu các thuộc tính theo một số điều kiện nhất định.
- Tại sao phải rút gọn
  - Tăng hiệu quả của mô hình: tăng tốc độ, độ chính xác và giảm độ phức tạp
  - Trực quan hóa dữ liệu
  - Giảm bớt nhiễu và những ảnh hưởng không cần thiết

| ID | Nhiệt độ | Đau đầu | Nôn mửa | Cúm |
|---|---|---|---|---|
| 1 | High | High | Yes | Yes |
| 2 | High | Low | No | No |
| 3 | Low | High | Yes | Yes |
| 4 | Low | Low | No | No |

# Lựa chọn mô hình (Model selection)

- Mô hình phù hợp với bài toán và dữ liệu
  - Phân loại ảnh, âm thanh hay văn bản
  - Dữ liệu rời rạc hay dữ liệu số
  - Nhiều hay ít thuộc tính
  - Phân loại hay phân cụm

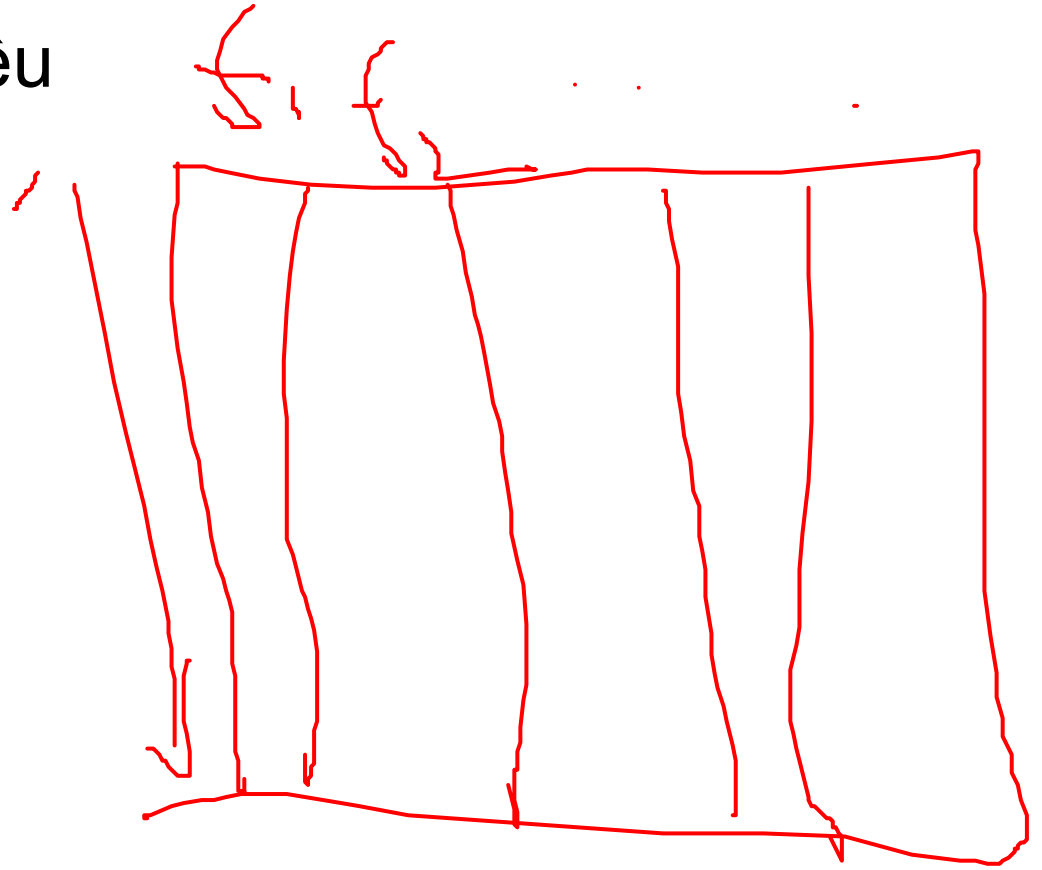

# Lựa chọn mô hình

- Lựa chọn siêu tham số (hyper parameter)
  - Decision trees
    - Độ sâu, số lượng lá
  - SVM
    - Kernel trick/feature extraction
  - Boosting
    - Number of rounds
  - Neural network
    - Learning rate
    - Mini-batch size…

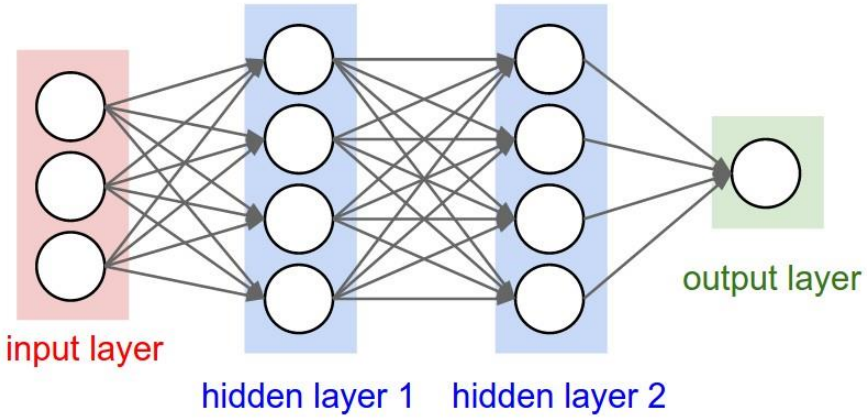

# Lựa chọn mô hình

- Lựa chọn siêu tham số (hyper parameter)

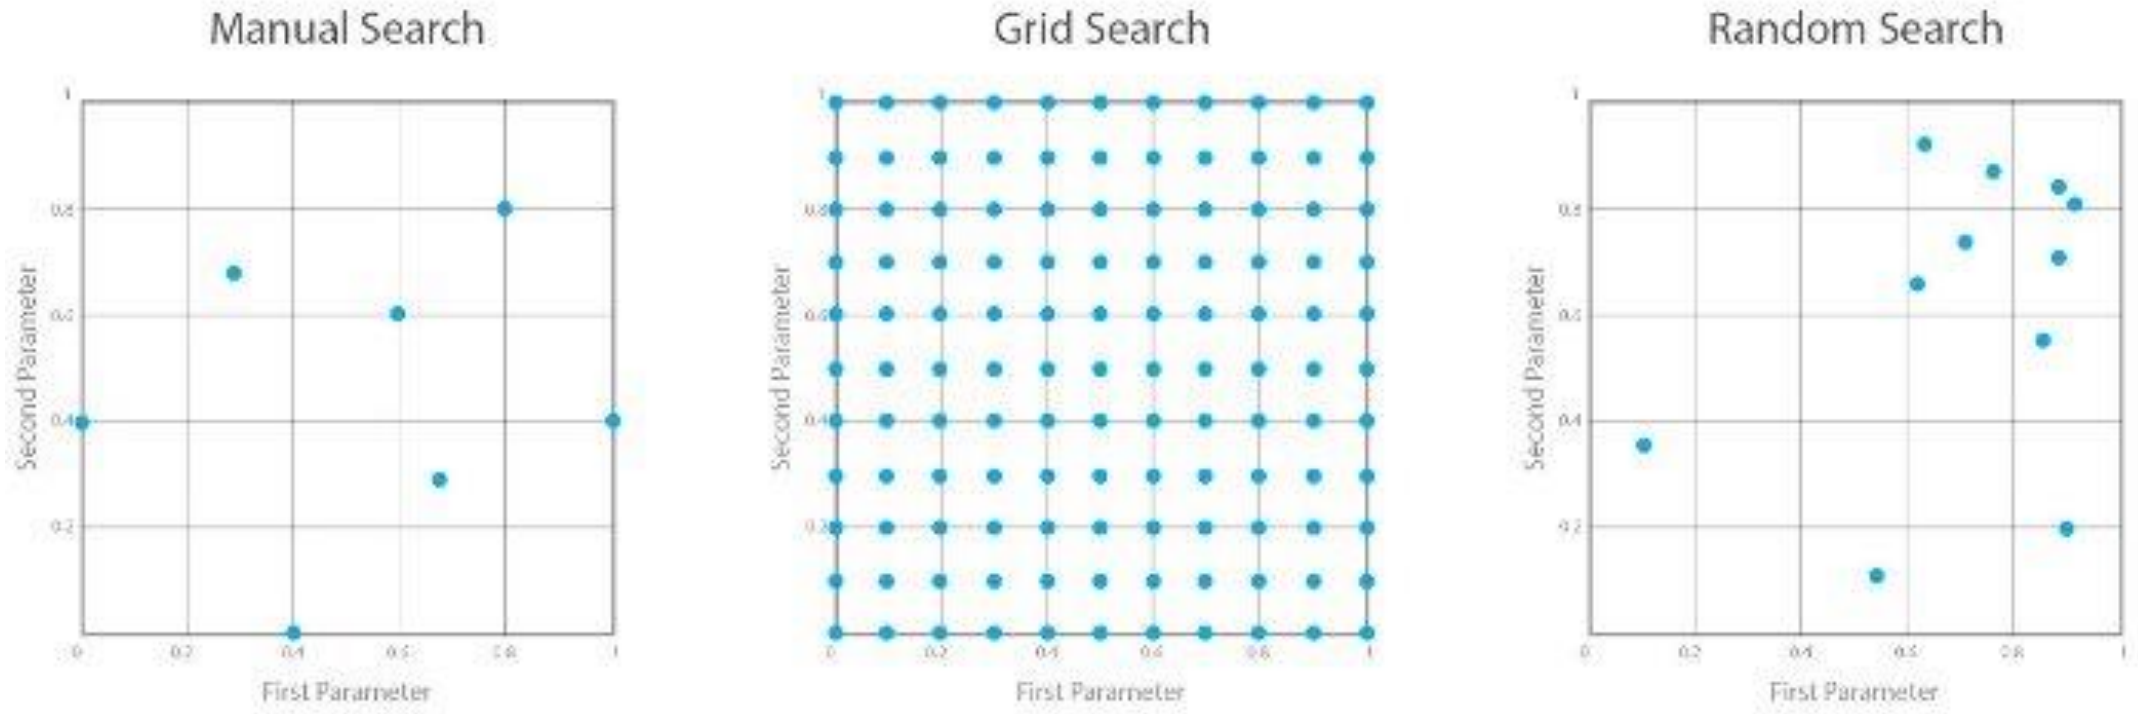

# Huấn luyện mô hình (Training)

- Là các bước tìm kiếm giá trị các tham số của mô hình sao cho mô hình xấp xỉ được tốt nhất phân bố của dữ liệu

$$y = f(\mathbf{x})$$

output prediction function Input data

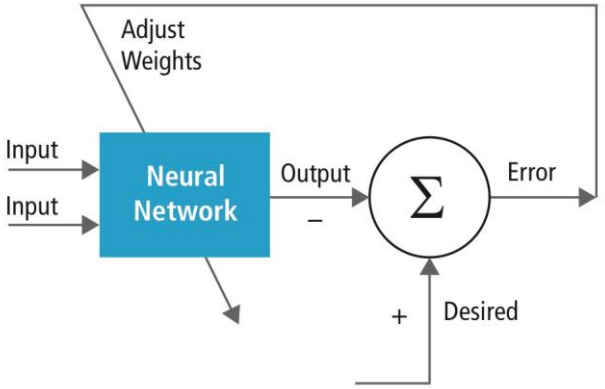


- **Huấn luyện:** cho một tập dữ liệu huấn luyện đã được gán nhãn $\{(\mathbf{x}_1,y_1), \ldots, (\mathbf{x}_N,y_N)\}$, ước lượng hàm dự đoán $f$ bằng cách cực tiểu hóa lỗi dự đoán
- **Kiểm tra:** áp dụng $f$ với dữ liệu mới (chưa được huấn luyện) $\mathbf{x}$ để dự đoán output $y = f(\mathbf{x})$

# Đánh giá (Evaluation)

- Đánh giá mô hình
  - Sử dụng dữ liệu kiểm tra (validation data, test data)
  - Tách biệt với tập huấn luyện
  - Đảm bảo tính khách quan
  - Ước lượng trước hiệu năng hệ thống khi vận hành thật

# Tập dữ liệu đánh giá mô hình

- Khi huấn luyện mô hình, chưa có dữ liệu kiểm tra
- Sử dụng một phần dữ liệu đã có để đánh giá mô hình trước khi sử dụng

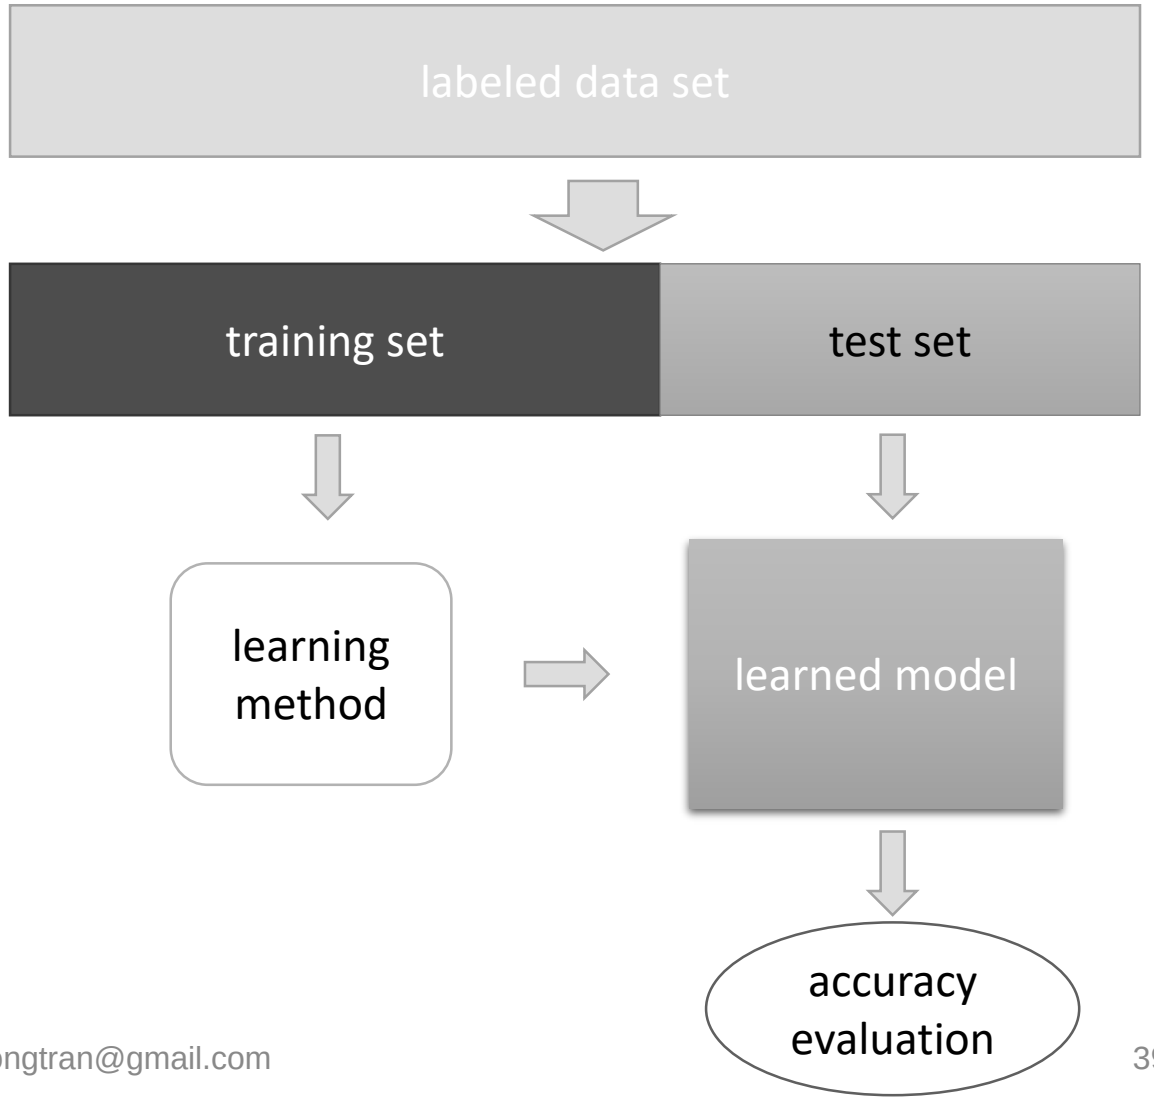

# Kiểm định (Validation)

- Kiểm định trong quá trình huấn luyện

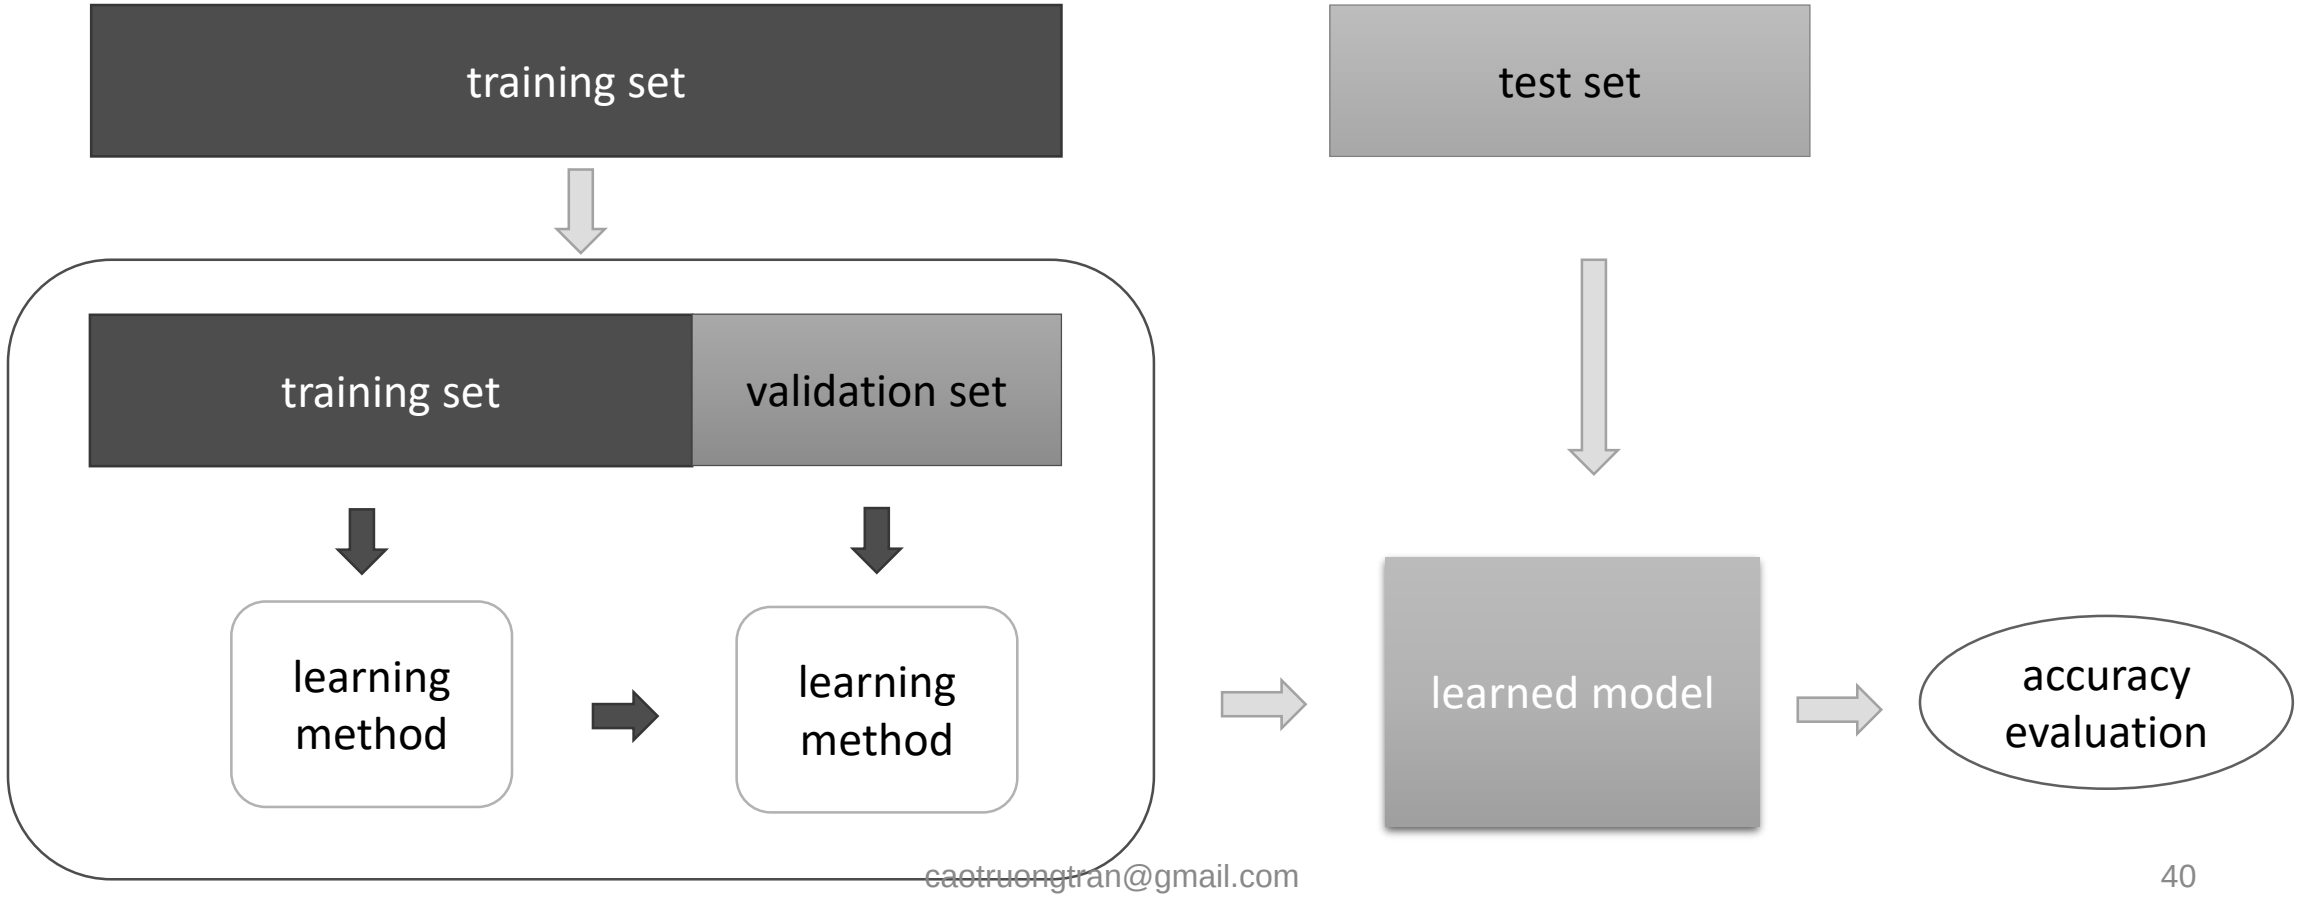

# Kiểm định chéo (Cross Validation)

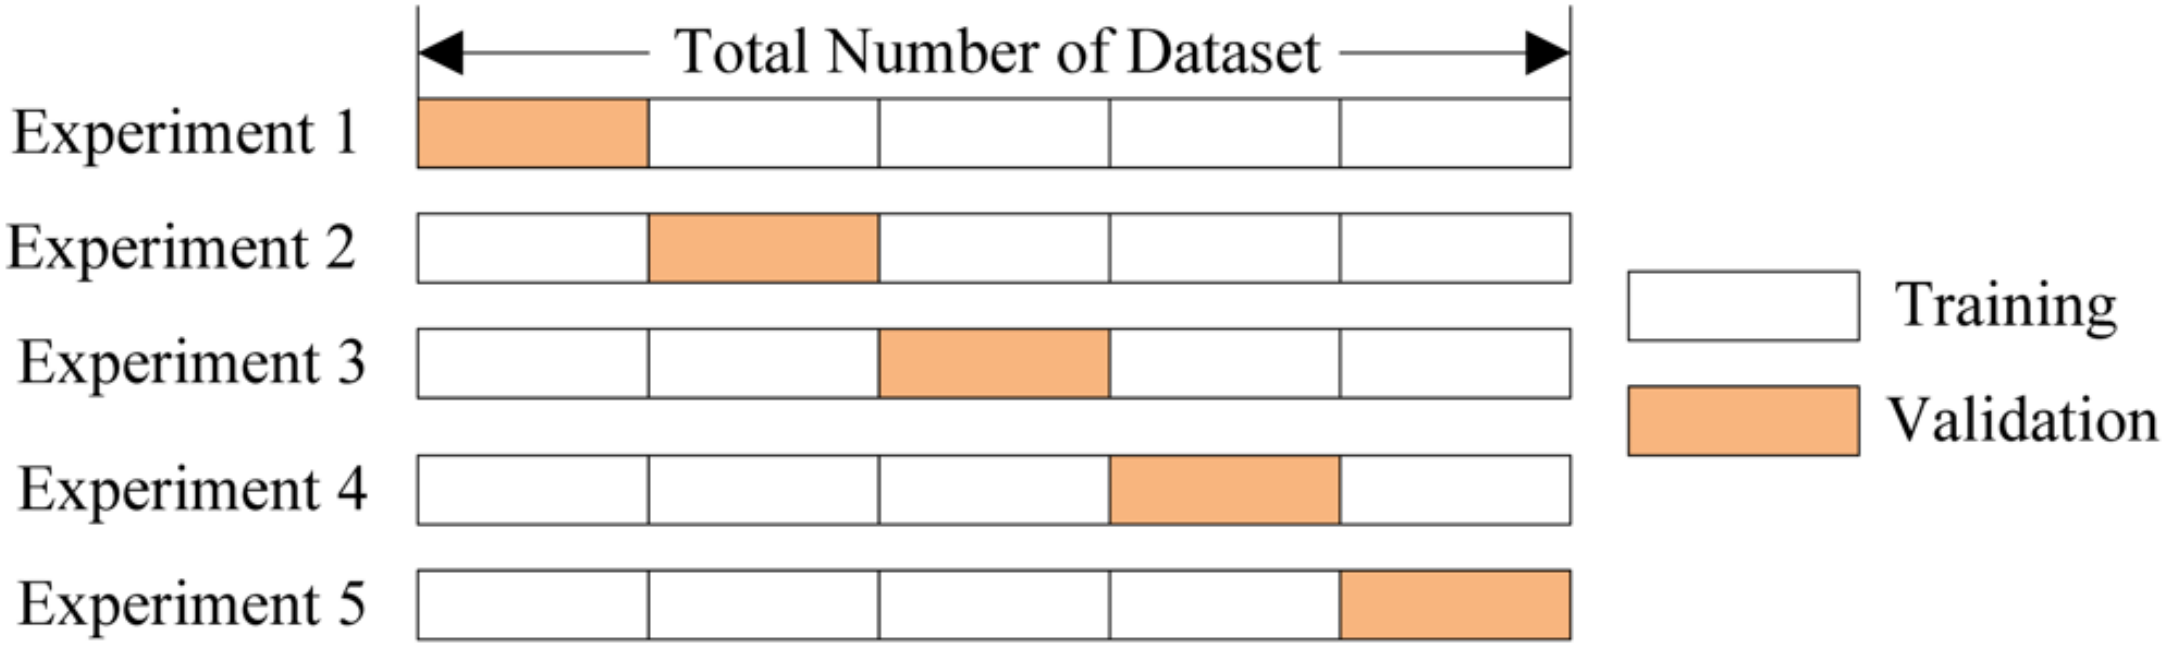

# Đánh giá (Evaluation)

| | | Predicted class: *yes* | Predicted class: *no* | |
|---|---|---|---|---|
| Actual class | *yes* | *TP* | *FN* | *P* |
| | *no* | *FP* | *TN* | *N* |
| | Total | $P'$ | $N'$ | $P + N$ |

| *Measure* | *Formula* |
|---|---|
| accuracy, recognition rate | $\frac{TP+TN}{P+N}$ |
| error rate, misclassification rate | $\frac{FP+FN}{P+N}$ |
| sensitivity, true positive rate, recall | $\frac{TP}{P}$ |
| precision | $\frac{TP}{TP+FP}$ |
| $F$, $F_1$, $F$-score, harmonic mean of precision and recall | $\frac{2 \times precision \times recall}{precision + recall}$ |
| $F_\beta$, where $\beta$ is a non-negative real number | $\frac{(1+\beta^2) \times precision \times recall}{\beta^2 \times precision + recall}$ |

# Tổng hợp

**Các thuật toán cơ bản**